

## Lista 2 (Integração e Expectativa)

- ① Seja  $(\Omega, \Sigma, \mathbb{P})$  um espaço de probabilidade, e  $Z_n \geq 0$ ,  $n \in \mathbb{N}$ , uma sequência de variáveis aleatórias não negativas.

- (a) Mostre que  $\mathbb{E}[\sum_{n=1}^{\infty} Z_n] = \sum_{n=1}^{\infty} \mathbb{E}[Z_n]$ .

**Resolução:**

Defina as somas parciais  $S_N := \sum_{n=1}^N Z_n$  e a soma (possivelmente estendida)  $S := \sum_{n=1}^{\infty} Z_n$ . Como  $Z_n \geq 0$ , temos  $S_N(\omega) \uparrow S(\omega)$  ponto a ponto.

Pelo Teorema da Convergência Monótona,

$$\mathbb{E}[S] = \lim_{N \rightarrow \infty} \mathbb{E}[S_N].$$

Mostremos que, para quaisquer  $X, Y \geq 0$  mensuráveis,  $\mathbb{E}[X + Y] = \mathbb{E}[X] + \mathbb{E}[Y]$ .

Para funções simples não negativas  $X = \sum_{i=1}^k a_i \mathbf{1}_{\{A_i\}}$  e  $Y = \sum_{j=1}^m b_j \mathbf{1}_{\{B_j\}}$ , refinamos para a partição disjunta  $\{A_i \cap B_j\}_{i,j}$  e usamos a definição de integral de Lebesgue para funções simples:

$$\mathbb{E}[X + Y] = \sum_{i,j} (a_i + b_j) \mathbb{P}(A_i \cap B_j) = \sum_i a_i \mathbb{P}(A_i) + \sum_j b_j \mathbb{P}(B_j) = \mathbb{E}[X] + \mathbb{E}[Y].$$

Para  $X, Y$  gerais não negativas, tome as aproximações em escada  $X_k := s_k \circ X$  e  $Y_k := s_k \circ Y$ . Então  $X_k \uparrow X$ ,  $Y_k \uparrow Y$  e, para cada  $k$ ,  $\mathbb{E}[X_k + Y_k] = \mathbb{E}[X_k] + \mathbb{E}[Y_k]$  (caso simples). Aplicando novamente a convergência monótona,

$$\mathbb{E}[X + Y] = \lim_{k \rightarrow \infty} \mathbb{E}[X_k + Y_k] = \lim_{k \rightarrow \infty} \mathbb{E}[X_k] + \lim_{k \rightarrow \infty} \mathbb{E}[Y_k] = \mathbb{E}[X] + \mathbb{E}[Y].$$

Por indução, a aditividade vale para qualquer soma finita de não negativas:  $\mathbb{E}\left[\sum_{n=1}^N Z_n\right] = \sum_{n=1}^N \mathbb{E}[Z_n]$  (valores em  $[0, \infty]$ ).

Combinando os dois passos:

$$\mathbb{E}\left[\sum_{n=1}^{\infty} Z_n\right] = \lim_{N \rightarrow \infty} \mathbb{E}\left[\sum_{n=1}^N Z_n\right] = \lim_{N \rightarrow \infty} \sum_{n=1}^N \mathbb{E}[Z_n] = \sum_{n=1}^{\infty} \mathbb{E}[Z_n].$$

A igualdade é válida sem assumir integrabilidade individual dos  $Z_n$ ; ambos os lados são entendidos em  $[0, \infty]$ .

- (b) Mostre que  $\mathbb{E}[\sum_{n=1}^{\infty} Z_n] < \infty \implies \mathbb{P}\{\omega : \sum_{n=1}^{\infty} Z_n(\omega) < \infty\} = 1$ .

**Resolução:**

Defina as somas parciais  $S_N := \sum_{n=1}^N Z_n$  e  $S := \sum_{n=1}^{\infty} Z_n = \lim_{N \rightarrow \infty} S_N$ . Como  $S_N \uparrow S$  ponto a ponto e cada  $S_N$  é mensurável,  $S$  é mensurável e  $S \geq 0$ .

Veja que  $\mathbb{E}[S] < \infty$ . Pelo lema de integração de Lebesgue para funções não negativas dos slides, “Se  $f \geq 0$  é mensurável e  $\mu(f) < \infty$ , então  $\mu(\{\omega : f(\omega) = \infty\}) = 0$ ”, tomando  $\mu = \mathbb{P}$  e  $f = S$  obtemos  $\mathbb{P}[S = \infty] = 0$ .

Logo,

$$\mathbb{P}\left(\left\{\omega : \sum_{n=1}^{\infty} Z_n(\omega) < \infty\right\}\right) = 1,$$

isto é, a soma  $\sum_{n=1}^{\infty} Z_n$  é finita  $\mathbb{P}$ -quase certamente.

(c) Mostre que  $\mathbb{P}[\{\omega : \sum_{n=1}^{\infty} Z_n(\omega) < \infty\}] = 1 \implies \mathbb{P}[\{\omega : Z_n(\omega) \not\rightarrow 0\}] = 0$ .

**Resolução:**

Sejam  $Z_n \geq 0$  e

$$E := \left\{ \omega : \sum_{n=1}^{\infty} Z_n(\omega) < \infty \right\}, \quad \mathbb{P}(E) = 1.$$

Para  $\omega \in E$ , as somas parciais  $S_N(\omega) := \sum_{n=1}^N Z_n(\omega)$  são crescentes e  $S_N(\omega) \uparrow S(\omega) := \sum_{n=1}^{\infty} Z_n(\omega) < \infty$ .

Considere as caudas  $T_n(\omega) := \sum_{k=n}^{\infty} Z_k(\omega) = S(\omega) - S_{n-1}(\omega)$ . Então  $T_{n+1}(\omega) \leq T_n(\omega)$  e  $T_n(\omega) \downarrow 0$  quando  $n \rightarrow \infty$ . Além disso,

$$0 \leq Z_n(\omega) \leq T_n(\omega) \quad \text{para todo } n,$$

logo  $Z_n(\omega) \rightarrow 0$  para todo  $\omega \in E$ .

Portanto  $E \subseteq \{\omega : Z_n(\omega) \rightarrow 0\}$ , e

$$\mathbb{P}\{\omega : Z_n(\omega) \not\rightarrow 0\} = 1 - \mathbb{P}\{\omega : Z_n(\omega) \rightarrow 0\} \leq 1 - \mathbb{P}(E) = 0.$$

Conclui-se que  $\mathbb{P}\{\omega : Z_n(\omega) \not\rightarrow 0\} = 0$ .

**Comentário:** o item (c) é exatamente o análogo probabilístico do “teste do termo geral” para séries: para cada  $\omega$ ,  $\sum_{n \geq 1} Z_n(\omega)$  é uma série de números reais, se converge, então  $Z_n(\omega) \rightarrow 0$ .

② Seja  $(\Omega, \Sigma, \mathbb{P})$  um espaço de probabilidade, e  $X$  uma variável aleatória. Mostre que, para todo  $f : \mathbb{R} \mapsto \mathbb{R}$  mensurável tal que  $\mathbb{E}[|f(X)|] < \infty$ .

$$\mathbb{E}[f(X)] = \int f(x) \mathbb{P}_X(dx),$$

onde  $\mathbb{P}_X$  é a medida de probabilidade induzida por  $X$  sobre  $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ . *Dica:* mostre para funções  $f$  simples, depois aproxime para funções não-negativas pelo teorema da convergência monótona, depois use a definição de integral para funções gerais.

**Solução:**

**Caso simples.**

Se  $f$  é simples,  $f = \sum_{i=1}^k a_i \mathbf{1}_{A_i}$  com  $A_i \in \mathcal{B}(\mathbb{R})$  disjuntos,

$$\mathbb{E}[f(X)] = \sum_{i=1}^k a_i \mathbb{E}[\mathbf{1}_{A_i}(X)] = \sum_{i=1}^k a_i \mathbb{P}(X \in A_i) = \sum_{i=1}^k a_i \mathbb{P}_X(A_i) = \int f \mathbb{P}_X(dx),$$

onde usamos a definição de integral de Lebesgue para funções simples e a definição de  $\mathbb{P}_X$ .

**Caso  $f \geq 0$ .**

Tome  $(f_n)_n$  funções simples não negativas tais que  $f_n \uparrow f$  em  $\mathbb{R}$  (por exemplo, aproximações por funções-escada). Então  $f_n(X) \uparrow f(X)$  em  $\Omega$ . Pelo Teorema da Convergência Monótona (TCM),

$$\mathbb{E}[f(X)] = \lim_{n \rightarrow \infty} \mathbb{E}[f_n(X)] = \lim_{n \rightarrow \infty} \int f_n \mathbb{P}_X(dx) = \int f \mathbb{P}_X(dx),$$

onde a segunda igualdade vem do caso simples e a última do TCM aplicado no espaço  $(\mathbb{R}, \mathcal{B}(\mathbb{R}), \mathbb{P}_X)$ .

**Caso geral integrável.**

Escreva  $f = f^+ - f^-$ , com  $f^+, f^- \geq 0$ . Como  $\mathbb{E}[|f(X)|] < \infty$ , temos  $\mathbb{E}[f^\pm(X)] < \infty$ . Aplicando o caso  $f \geq 0$  a  $f^+$  e  $f^-$ ,

$$\mathbb{E}[f(X)] = \mathbb{E}[f^+(X)] - \mathbb{E}[f^-(X)] = \int f^+ \mathbb{P}_X(dx) - \int f^- \mathbb{P}_X(dx) = \int f \mathbb{P}_X(dx).$$

**Comentário:** Veja que esse problema indica que não é necessário, ao lidarmos com funções de variáveis aleatórias, saber muito mais do que a distribuição da variável aleatória original. A esperança em questão, pela definição, seria calculada como:

$$\mathbb{E}[f(X)] = \int_{\Omega} f(X(\omega)) \mathbb{P}(d\omega) = \int_{\mathbb{R}} y \mathbb{P}_{f(X)}(dy),$$

mas **nada sabemos (pelo exposto em aula) sobre  $\mathbb{P}_{f(X)}$** , esse teorema mostra que isso é uma complicação desnecessária e pode ser facilmente ignorada (tanto que na prática muitas pessoas esquecem que isso é um resultado que precisa ser provado e tomam isso como parte da definição), por isso coloquialmente é chamado de **Teorema do Estatístico Inconsciente**.

- ③ Demonstre a desigualdade de Jensen *estrita*: se  $X$  é uma variável aleatória integrável sobre um espaço de probabilidade  $(\Omega, \Sigma, \mathbb{P})$ ,  $f : A \mapsto \mathbb{R}$  uma função **estritamente** convexa sobre  $A \subseteq \mathbb{R}$  convexo e aberto, com  $\mathbb{P}[X \in A] = 1$  e  $\mathbb{E}[|X|] < \infty$ ,  $\mathbb{E}[|f(X)|] < \infty$ . Se  $\mathbb{P}[X \neq \mathbb{E}[X]] > 0$ , então:

$$f(\mathbb{E}[X]) < \mathbb{E}[f(X)]$$

### Resolução:

Denote  $m := \mathbb{E}[X]$  (note que, como  $A$  é um intervalo aberto e  $X \in A$  q.c., necessariamente  $m \in A$ ). Suponha  $\mathbb{P}[X \neq m] > 0$ . Mostraremos que

$$f(m) < \mathbb{E}[f(X)].$$

Considere os eventos  $B := \{X \leq m\}$  e  $C := \{X > m\}$ . Da hipótese  $\mathbb{P}[X \neq m] > 0$  e do fato de  $\mathbb{E}[X] = m$ , segue que  $\mathbb{P}(B) \in (0, 1)$  e  $\mathbb{P}(C) \in (0, 1)$  (se, por exemplo,  $\mathbb{P}(C) = 0$ , então  $X \leq m$  q.c. e, com  $\mathbb{P}(X < m) > 0$ , teríamos  $\mathbb{E}[X] < m$ , contradição). Defina

$$m_1 := \mathbb{E}[X | B], \quad m_2 := \mathbb{E}[X | C].$$

Como  $X \leq m$  em  $B$  e  $\mathbb{P}(X < m) > 0$ , temos  $m_1 < m$ ; analogamente,  $m_2 > m$ . Além disso,

$$m = \mathbb{E}[X] = \mathbb{E}[X \mathbf{1}_B] + \mathbb{E}[X \mathbf{1}_C] = \mathbb{P}(B) m_1 + \mathbb{P}(C) m_2.$$

Pela estrita convexidade de  $f$  em  $A$  e pelo fato de  $m_1 \neq m_2$  e  $\mathbb{P}(B) \in (0, 1)$ ,

$$f(m) = f(\mathbb{P}(B)m_1 + \mathbb{P}(C)m_2) < \mathbb{P}(B)f(m_1) + \mathbb{P}(C)f(m_2).$$

Por outro lado, aplicando Jensen condicional à  $\sigma$ -álgebra gerada pela partição  $\{B, C\}$ ,

$$\mathbb{E}[f(X) | \sigma(B)] \geq f(\mathbb{E}[X | \sigma(B)]) = f(m_1 \mathbf{1}_B + m_2 \mathbf{1}_C) \quad \text{q.c.}$$

Tomando esperanças,

$$\mathbb{E}[f(X)] \geq \mathbb{P}(B) f(m_1) + \mathbb{P}(C) f(m_2).$$

Combinando, obtemos

$$f(\mathbb{E}[X]) < \mathbb{E}[f(X)],$$

como desejado.

- ④ Seja  $(\Omega, \Sigma, \mathbb{P})$  um espaço de probabilidade. Para  $A, B \in \mathcal{L}_2(\Omega, \Sigma, \mathbb{P})$  a covariância entre  $A$  e  $B$  é definida como:

$$\mathbb{C}(A, B) := \mathbb{E}[AB] - \mathbb{E}[A]\mathbb{E}[B].$$

Para duas variáveis aleatórias  $X, Y$  definidas em  $(\Omega, \Sigma, \mathbb{P})$ , mostre que  $X$  é independente de  $Y$  se, e somente se, para quaisquer funções  $h : \mathbb{R} \mapsto \mathbb{R}$  e  $g : \mathbb{R} \mapsto \mathbb{R}$  limitadas e mensuráveis:

$$\mathbb{C}(h(X), g(Y)) = 0.$$

*Dica:* para a direção “se”, observe que, para todo  $B \in \mathcal{B}(\mathbb{R})$ ,  $\mathbb{P}[X^{-1}(B)] = \mathbb{E}[\mathbf{1}_{X^{-1}(B)}] = \mathbb{E}[\mathbf{1}_B(X)]$ . Para a outra direção, mostre para funções simples e depois aproxime para funções limitadas por funções-escada.

### Resolução:

( $\Leftarrow$ ) Suponha que para quaisquer  $h, g$  limitadas e mensuráveis temos  $\mathbb{E}[h(X)g(Y)] = \mathbb{E}[h(X)]\mathbb{E}[g(Y)]$ . Tome  $A, B \in \mathcal{B}(\mathbb{R})$  e escolha  $h = \mathbf{1}_A$ ,  $g = \mathbf{1}_B$ . Então

$$\mathbb{E}[\mathbf{1}_A(X)\mathbf{1}_B(Y)] = \mathbb{E}[\mathbf{1}_A(X)]\mathbb{E}[\mathbf{1}_B(Y)].$$

Usando que  $\mathbf{1}_A(X) = \mathbf{1}_{X^{-1}(A)}$  e  $\mathbb{E}[\mathbf{1}_E] = \mathbb{P}(E)$  para qualquer evento  $E \in \Sigma$ , obtemos

$$\mathbb{P}(X \in A, Y \in B) = \mathbb{P}(X \in A)\mathbb{P}(Y \in B).$$

Como  $A, B$  são arbitrários em  $\mathcal{B}(\mathbb{R})$ , segue que  $X$  e  $Y$  são independentes.

( $\Rightarrow$ ) Suponha agora que  $X$  e  $Y$  são independentes, isto é, para todo  $A, B \in \mathcal{B}(\mathbb{R})$ ,

$$\mathbb{P}(X \in A, Y \in B) = \mathbb{P}(X \in A)\mathbb{P}(Y \in B).$$

Primeiro verificamos a fatoração de esperanças para funções simples e depois passamos ao caso geral por aproximação por funções-escada e pelo teorema da convergência limitada.

### Indicadoras.

Para  $A, B \in \mathcal{B}(\mathbb{R})$ ,

$$\mathbb{E}[\mathbf{1}_A(X)\mathbf{1}_B(Y)] = \mathbb{P}(X \in A, Y \in B) = \mathbb{P}(X \in A)\mathbb{P}(Y \in B) = \mathbb{E}[\mathbf{1}_A(X)]\mathbb{E}[\mathbf{1}_B(Y)].$$

### Funções simples.

Sejam  $h = \sum_{i=1}^k a_i \mathbf{1}_{A_i}$  e  $g = \sum_{j=1}^m b_j \mathbf{1}_{B_j}$  funções simples com  $A_i, B_j \in \mathcal{B}(\mathbb{R})$  (podemos supor  $A_i$  e  $B_j$  disjuntos). Então

$$h(X)g(Y) = \sum_{i=1}^k \sum_{j=1}^m a_i b_j \mathbf{1}_{A_i}(X) \mathbf{1}_{B_j}(Y),$$

e, pela linearidade da esperança,

$$\mathbb{E}[h(X)g(Y)] = \sum_{i=1}^k \sum_{j=1}^m a_i b_j \mathbb{E}[\mathbf{1}_{A_i}(X) \mathbf{1}_{B_j}(Y)].$$

Pela independência (no caso de indicadoras),  $\mathbb{E}[\mathbf{1}_{A_i}(X) \mathbf{1}_{B_j}(Y)] = \mathbb{E}[\mathbf{1}_{A_i}(X)]\mathbb{E}[\mathbf{1}_{B_j}(Y)]$ , logo

$$\begin{aligned} \mathbb{E}[h(X)g(Y)] &= \sum_{i=1}^k \sum_{j=1}^m a_i b_j \mathbb{E}[\mathbf{1}_{A_i}(X)] \mathbb{E}[\mathbf{1}_{B_j}(Y)] \\ &= \left( \sum_{i=1}^k a_i \mathbb{E}[\mathbf{1}_{A_i}(X)] \right) \left( \sum_{j=1}^m b_j \mathbb{E}[\mathbf{1}_{B_j}(Y)] \right) \\ &= \mathbb{E}[h(X)] \mathbb{E}[g(Y)]. \end{aligned}$$

**Funções limitadas e mensuráveis.** Sejam agora  $h, g : \mathbb{R} \rightarrow \mathbb{R}$  limitadas e mensuráveis. Escolha  $M_h = \|h\|_\infty$  e defina  $u = h + M_h$ , de modo que  $u \geq 0$  e  $u \leq 2M_h$ . Considere as funções-escada  $s_n$  (definidas em  $[0, \infty)$ ) e ponha

$$u_n = s_n \circ u, \quad h_n = u_n - M_h.$$

Então  $u_n$  é simples,  $0 \leq u_n \leq u$  e  $u_n \uparrow u$  ponto a ponto; portanto  $h_n$  é simples,  $|h_n| \leq M_h$  e  $h_n \rightarrow h$  ponto a ponto. Fazendo o mesmo para  $g$ , obtemos funções simples  $g_n$  com  $|g_n| \leq M_g = \|g\|_\infty$  e  $g_n \rightarrow g$  ponto a ponto.

Como  $h_n$  e  $g_n$  são simples, já mostramos que para todo  $n$ ,

$$\mathbb{E}[h_n(X)g_n(Y)] = \mathbb{E}[h_n(X)]\mathbb{E}[g_n(Y)].$$

Além disso, temos convergência quase certa  $h_n(X) \rightarrow h(X)$ ,  $g_n(Y) \rightarrow g(Y)$  e  $h_n(X)g_n(Y) \rightarrow h(X)g(Y)$ , e as cotas uniformes

$$|h_n(X)| \leq M_h, \quad |g_n(Y)| \leq M_g, \quad |h_n(X)g_n(Y)| \leq M_h M_g \quad \text{q.c.}$$

Pelo Teorema da Convergência Limitada, concluímos que

$$\mathbb{E}[h_n(X)] \rightarrow \mathbb{E}[h(X)], \quad \mathbb{E}[g_n(Y)] \rightarrow \mathbb{E}[g(Y)], \quad \mathbb{E}[h_n(X)g_n(Y)] \rightarrow \mathbb{E}[h(X)g(Y)].$$

Tomando limite na identidade para cada  $n$ , obtemos

$$\mathbb{E}[h(X)g(Y)] = \mathbb{E}[h(X)]\mathbb{E}[g(Y)],$$

isto é,  $C(h(X), g(Y)) = 0$ .

Combinando as duas implicações, provamos o que foi pedido.

**5** Seja  $(\Omega, \Sigma, \mathbb{P})$  e  $Y \in L^2(\Omega, \Sigma, \mathbb{P})$ . Seja  $\mathcal{G}$  uma sub- $\sigma$ -álgebra de  $\Sigma$ .

(a) Mostre que  $\mathbb{E}[Y|\mathcal{G}] \in L^2(\Omega, \Sigma, \mathbb{P})$ .

**Resolução:**

Como  $Y \in L^2(\Omega, \Sigma, \mathbb{P})$ , pela monotonicidade das normas  $L^p$  (com  $p = 1$ ,  $q = 2$ ) temos  $Y \in L^1$ . Logo  $\mathbb{E}[Y|\mathcal{G}]$  está bem definida.

Pela desigualdade de Jensen condicional, para a função convexa  $\phi(t) = t^2$  e usando que  $\mathbb{E}[|Y|^2] < \infty$ ,

$$\mathbb{E}[Y^2|\mathcal{G}] \geq (\mathbb{E}[Y|\mathcal{G}])^2 \quad \text{quase certamente.}$$

Tomando esperança em ambos os lados e usando preservação da esperança,

$$\mathbb{E}[(\mathbb{E}[Y|\mathcal{G}])^2] \leq \mathbb{E}[\mathbb{E}[Y^2|\mathcal{G}]] = \mathbb{E}[Y^2] < \infty.$$

Portanto,  $\mathbb{E}[Y|\mathcal{G}] \in L^2(\Omega, \Sigma, \mathbb{P})$ .

(b) Mostre que  $\mathbb{E}[Y|\mathcal{G}]$  é a única (a não ser num evento de probabilidade zero) solução ao problema de minimização:

$$\min_{S \in L^2(\Omega, \mathcal{G}, \mathbb{P})} \mathbb{E}[(Y - S)^2]$$

**Resolução:**

Fixe  $S \in L^2(\Omega, \mathcal{G}, \mathbb{P})$  e defina:

$$M := \mathbb{E}[Y|\mathcal{G}].$$

Então  $M \in L^2$  pelo item (a),  $M$  é  $\mathcal{G}$ -mensurável, e  $S - M \in L^2(\Omega, \mathcal{G}, \mathbb{P})$ . Expandindo,

$$(Y - S)^2 = (Y - M + M - S)^2 = (Y - M)^2 + (S - M)^2 + 2(Y - M)(M - S).$$

Tomando esperança,

$$\mathbb{E}[(Y - S)^2] = \mathbb{E}[(Y - M)^2] + \mathbb{E}[(S - M)^2] + 2\mathbb{E}[(Y - M)(M - S)].$$

Mostremos que o termo cruzado é nulo. Primeiro, pela linearidade e pela propriedade de mensurabilidade,

$$\mathbb{E}[Y - M \mid \mathcal{G}] = \mathbb{E}[Y \mid \mathcal{G}] - \mathbb{E}[M \mid \mathcal{G}] = M - M = 0 \quad \text{quase certamente.}$$

Como  $M - S$  é  $\mathcal{G}$ -mensurável e  $Y - M \in L^2$ ,  $M - S \in L^2$ , podemos usar a propriedade “extraindo o que é conhecido” na forma  $L^p$ - $L^q$  (com  $p = q = 2$ ) para obter

$$\mathbb{E}[(Y - M)(M - S) \mid \mathcal{G}] = (M - S) \mathbb{E}[Y - M \mid \mathcal{G}] = (M - S) \cdot 0 = 0 \quad \text{q.c.}$$

Logo,

$$\mathbb{E}[(Y - M)(M - S)] = \mathbb{E}[\mathbb{E}[(Y - M)(M - S) \mid \mathcal{G}]] = 0.$$

Substituindo na identidade anterior,

$$\mathbb{E}[(Y - S)^2] = \mathbb{E}[(Y - M)^2] + \mathbb{E}[(S - M)^2] \geq \mathbb{E}[(Y - M)^2].$$

Assim,  $M = \mathbb{E}[Y \mid \mathcal{G}]$  é o minimizador de  $f(s) = \mathbb{E}[(Y - s)^2]$

Para a unicidade (a menos de um evento de probabilidade zero), suponha que  $S^* \in L^2(\Omega, \mathcal{G}, \mathbb{P})$  também atinja o mínimo. Então

$$\mathbb{E}[(Y - S^*)^2] = \mathbb{E}[(Y - M)^2] \Rightarrow \mathbb{E}[(S^* - M)^2] = 0.$$

Como  $(S^* - M)^2 \geq 0$ , do lema básico sobre integrais de funções não negativas conclui-se que

$$\mathbb{P}[(S^* - M)^2 > 0] = 0,$$

isto é,  $S^* = M$  quase certamente.

- (c) Mostre que, quando  $\mathcal{G} = \{\emptyset, \Omega\}$ ,  $\mathbb{E}[Y \mid \mathcal{G}] = \mathbb{E}[Y]$ , e que, quando  $\mathcal{G} = \Sigma$ ,  $\mathbb{E}[Y \mid \mathcal{G}] = Y$ . À luz do item anterior, qual a interpretação desses resultados?

**Resolução:**

Se  $\mathcal{G} = \{\emptyset, \Omega\}$ , toda variável aleatória  $\mathcal{G}$ -mensurável é constante quase certamente. Seja  $Z = \mathbb{E}[Y \mid \mathcal{G}]$ . Então existe  $c \in \mathbb{R}$  tal que  $Z = c$  q.c. Pela definição da esperança condicional,

$$\mathbb{E}[Z] = \mathbb{E}[Y] \Rightarrow c = \mathbb{E}[Y],$$

logo  $\mathbb{E}[Y \mid \mathcal{G}] = \mathbb{E}[Y]$  q.c.

Se  $\mathcal{G} = \Sigma$ , então  $Y$  é  $\mathcal{G}$ -mensurável e, pela propriedade de mensurabilidade,

$$\mathbb{E}[Y \mid \Sigma] = Y \quad \text{q.c.}$$

Interpretação pelo item (b): quando  $\mathcal{G} = \{\emptyset, \Omega\}$ , o agente não tem informação após o sorteio (só pode escolher aproximações constantes), e a melhor aproximação quadrática é a constante  $\mathbb{E}[Y]$ . Quando  $\mathcal{G} = \Sigma$ , o agente observa toda a informação possível (pode escolher  $S = Y$ ), e o erro quadrático mínimo é zero.

(d) Seja  $E \in \Sigma$ , com  $1 > \mathbb{P}[E] > 0$ . Tome  $\mathcal{G} = \{\emptyset, E, E^c, \Omega\}$ . Mostre que a função:

$$g(\omega) = \begin{cases} \frac{\mathbb{E}[Y\mathbf{1}_E]}{\mathbb{P}[E]}, & \text{se } \omega \in E \\ \frac{\mathbb{E}[Y\mathbf{1}_{E^c}]}{\mathbb{P}[E^c]}, & \text{se } \omega \in E^c \end{cases},$$

é uma versão de  $\mathbb{E}[Y|\mathcal{G}]$ . Qual a interpretação desse resultado, à luz do item (b)?

**Resolução:**

Defina  $Z : \Omega \rightarrow \mathbb{R}$  por

$$Z(\omega) = \frac{\mathbb{E}[Y\mathbf{1}_E]}{\mathbb{P}[E]} \mathbf{1}_E(\omega) + \frac{\mathbb{E}[Y\mathbf{1}_{E^c}]}{\mathbb{P}[E^c]} \mathbf{1}_{E^c}(\omega).$$

Como  $Z$  é constante em  $E$  e em  $E^c$ , temos que  $Z$  é  $\mathcal{G}$ -mensurável, onde  $\mathcal{G} = \{\emptyset, E, E^c, \Omega\}$ . Além disso,  $Z \in L^2$  (em particular, é integrável): por Cauchy–Schwarz,

$$(\mathbb{E}[Y\mathbf{1}_E])^2 \leq \mathbb{E}[Y^2\mathbf{1}_E] \mathbb{P}[E] \leq \mathbb{E}[Y^2] \mathbb{P}[E],$$

logo

$$\mathbb{E}[Z^2] = \frac{(\mathbb{E}[Y\mathbf{1}_E])^2}{\mathbb{P}[E]} + \frac{(\mathbb{E}[Y\mathbf{1}_{E^c}])^2}{\mathbb{P}[E^c]} \leq \mathbb{E}[Y^2] + \mathbb{E}[Y^2] < \infty.$$

Para verificar que  $Z$  é uma versão de  $\mathbb{E}[Y|\mathcal{G}]$ , basta checar a identidade de definição nos geradores  $E$  e  $E^c$ . Para  $A = E$ ,

$$\mathbb{E}[Z\mathbf{1}_E] = \mathbb{E}\left[\frac{\mathbb{E}[Y\mathbf{1}_E]}{\mathbb{P}[E]} \mathbf{1}_E\right] = \frac{\mathbb{E}[Y\mathbf{1}_E]}{\mathbb{P}[E]} \mathbb{P}[E] = \mathbb{E}[Y\mathbf{1}_E].$$

Analogamente, para  $A = E^c$ ,

$$\mathbb{E}[Z\mathbf{1}_{E^c}] = \mathbb{E}[Y\mathbf{1}_{E^c}].$$

Por linearidade, a identidade vale também para  $A = \Omega$  e  $A = \emptyset$ . Logo  $Z$  satisfaz a caracterização e é uma versão de  $\mathbb{E}[Y|\mathcal{G}]$ .

Interpretação pelo item (b): ao restringir  $S$  a ser  $\mathcal{G}$ -mensurável, estamos restringindo  $S$  a ser constante em  $E$  e em  $E^c$ , isto é, uma previsão baseada apenas na informação binária de ocorrer  $E$  ou não. O minimizador do erro quadrático médio escolhe, em cada átomo da partição  $\{E, E^c\}$ , o melhor valor constante, que é a média de  $Y$  condicionada ao átomo:

$$Z(\omega) = \mathbb{E}[Y|E] \text{ em } E, \quad Z(\omega) = \mathbb{E}[Y|E^c] \text{ em } E^c.$$

- ⑥ Seja  $(\Omega, \Sigma, \mathbb{P})$ , e  $X$  e  $Y$  duas variáveis aleatórias reais. Considere  $\mathbb{P}_{X,Y} := \mathbb{P}[\{\omega : (X(\omega), Y(\omega)) \in B\}]$ ,  $B \in \mathcal{B}(\mathbb{R}^2)$ , a medida de probabilidade induzida por  $(X, Y)$  em  $(\mathbb{R}^2, \mathcal{B}(\mathbb{R}^2))$ . Dizemos que  $\mathbb{P}_{X,Y}$  admite densidade  $f$  com respeito a medida de Lebesgue  $\lambda^2$  em  $(\mathbb{R}^2, \mathcal{B}(\mathbb{R}^2))$ <sup>1</sup> se, para todo  $B \in \mathcal{B}(\mathbb{R}^2)$ :

$$\mathbb{P}_{X,Y} = \int f(\omega_1, \omega_2) \mathbf{1}_B(\omega_1, \omega_2) \lambda(d\omega),$$

onde, por uma extensão do resultado visto em aula,  $\lambda(d\omega)$  pode ser substituída pela integral dupla (de Riemann) quando  $(\omega_1, \omega_2) \mapsto f(\omega_1, \omega_2) \mathbf{1}_B(\omega_1, \omega_2)$  for Riemann-integrável.

<sup>1</sup>A medida de Lebesgue em  $\mathbb{R}^2$  é igual à medida produto  $\lambda \otimes \lambda$  sobre  $\mathcal{B}(\mathbb{R}) \otimes \mathcal{B}(\mathbb{R}) = \mathcal{B}(\mathbb{R}^2)$ , onde  $\lambda$  é a medida de Lebesgue em  $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$

- (a) Mostre que  $f_1(\omega) := \int f(\omega, y) \lambda(dy)$  define uma densidade para a probabilidade  $\mathbb{P}_X$  induzida sobre  $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ . *Dica:* tome  $A \in \mathcal{B}(\mathbb{R})$  e use o teorema de Fubini para mostrar que  $\mathbb{P}_X = \mathbb{P}_{X,Y}[A \times \mathbb{R}] = \int \mathbf{1}_{A \times \mathbb{R}} f d\lambda^2 = \int \mathbf{1}_A f_1 d\lambda_1$ .

**Resolução:**

Como  $\mathbb{P}_{X,Y}$  admite densidade  $f$  com respeito a  $\lambda^2$ , temos  $f \geq 0$  mensurável e

$$\int_{\mathbb{R}^2} f(x, y) \lambda^2(d(x, y)) = P_{X,Y}(\mathbb{R}^2) = 1,$$

logo  $f \in L^1(\mathbb{R}^2, \mathcal{B}(\mathbb{R}^2), \lambda^2)$ . Pelo Teorema de Fubini, a função

$$f_1(x) := \int_{\mathbb{R}} f(x, y) \lambda(dy)$$

é bem definida para  $\lambda$ -q.t.p.  $x$ , é mensurável e não negativa.

Para  $A \in \mathcal{B}(\mathbb{R})$ ,

$$\begin{aligned} \mathbb{P}_X(A) &= \mathbb{P}(X \in A) = \mathbb{P}((X, Y) \in A \times \mathbb{R}) = \mathbb{P}_{X,Y}(A \times \mathbb{R}) \\ &= \int_{\mathbb{R}^2} \mathbf{1}_{A \times \mathbb{R}}(x, y) f(x, y) \lambda^2(d(x, y)) \\ &= \int_{\mathbb{R}} \left( \int_{\mathbb{R}} \mathbf{1}_A(x) f(x, y) \lambda(dy) \right) \lambda(dx) \\ &= \int_{\mathbb{R}} \mathbf{1}_A(x) \left( \int_{\mathbb{R}} f(x, y) \lambda(dy) \right) \lambda(dx) = \int_A f_1(x) \lambda(dx). \end{aligned}$$

Em particular, tomando  $A = \mathbb{R}$  obtemos  $\int_{\mathbb{R}} f_1 d\lambda = 1$ . Portanto,  $f_1$  é uma densidade de  $P_X$  com respeito a  $\lambda$ .

- (b) Suponha que  $\mathbb{E}[|Y|] < \infty$ . Mostre que a função  $g : \mathbb{R} \mapsto \mathbb{R}$ :

$$g(x) = \begin{cases} \frac{1}{f_1(x)} \int y f(y, x) \lambda(dy), & \text{se } f_1(x) > 0 \\ 0, & \text{se } f_1(x) = 0 \end{cases},$$

define uma função de expectativa condicional de  $Y$  em  $X$ , i.e. que  $g(X)$  é uma versão de  $\mathbb{E}[Y|X]$ . A escolha, na definição de  $g$ , do valor 0 quando  $f_1(x) = 0$ , faz alguma diferença? Por quê?

**Resolução:**

Como  $\mathbb{E}[|Y|] < \infty$  e  $\lambda^2$  admite densidade, generalizando o **Exercício 2**,

$$\mathbb{E}[|Y|] = \int_{\mathbb{R}^2} |y| f(x, y) \lambda^2(d(x, y)) < \infty,$$

logo a função  $(x, y) \mapsto y f(x, y)$  é integrável em valor absoluto. Pelo Teorema de Fubini,

$$m(x) := \int_{\mathbb{R}} y f(x, y) \lambda(dy)$$

é (finita para  $\lambda$ -q.t.p.  $x$  e) mensurável.

Defina

$$g(x) := \begin{cases} \frac{m(x)}{f_1(x)}, & \text{se } f_1(x) > 0, \\ 0, & \text{se } f_1(x) = 0. \end{cases}$$



Então  $g$  é mensurável e  $g(X)$  é  $\sigma(X)$ -mensurável.

Além disso,  $g(X)$  é integrável (pelo mesmo argumento do **Exercício 2**):

$$\begin{aligned}\mathbb{E}[|g(X)|] &= \int_{\mathbb{R}} |g(x)| f_1(x) \lambda(dx) = \int_{\{f_1 > 0\}} \left| \frac{m(x)}{f_1(x)} \right| f_1(x) \lambda(dx) \\ &= \int_{\{f_1 > 0\}} |m(x)| \lambda(dx) \leq \int_{\mathbb{R}} \left( \int_{\mathbb{R}} |y| f(x, y) \lambda(dy) \right) \lambda(dx) \\ &= \int_{\mathbb{R}^2} |y| f(x, y) \lambda^2(d(x, y)) = \mathbb{E}[|Y|] < \infty.\end{aligned}$$

Para verificar a caracterização de esperança condicional com respeito a  $\sigma(X)$ , basta checar nos eventos  $\{X \in A\}$ ,  $A \in \mathcal{B}(\mathbb{R})$ . Note que, se  $f_1(x) = 0$ , então

$$\int_{\mathbb{R}} f(x, y) \lambda(dy) = 0.$$

Como  $y \mapsto f(x, y)$  é não negativa, pelo lema básico para integrais de funções não negativas,

$$\lambda(\{y : f(x, y) > 0\}) = 0,$$

isto é,  $f(x, y) = 0$  para  $\lambda$ -q.t.p.  $y$ , e portanto  $m(x) = \int y f(x, y) dy = 0$ . Logo, para todo  $x$ ,

$$g(x) f_1(x) = m(x).$$

Assim, para  $A \in \mathcal{B}(\mathbb{R})$ ,

$$\begin{aligned}\mathbb{E}[g(X) \mathbf{1}_{\{X \in A\}}] &= \int_{\mathbb{R}} g(x) \mathbf{1}_A(x) f_1(x) \lambda(dx) = \int_A g(x) f_1(x) \lambda(dx) = \int_A m(x) \lambda(dx) \\ &= \int_A \left( \int_{\mathbb{R}} y f(x, y) \lambda(dy) \right) \lambda(dx) = \int_{\mathbb{R}^2} y \mathbf{1}_A(x) f(x, y) \lambda^2(d(x, y)).\end{aligned}$$

Usando de novo o **Exercício 2** generalizado em duas dimensões, o último termo é

$$\int_{\mathbb{R}^2} y \mathbf{1}_A(x) f(x, y) \lambda^2(d(x, y)) = \mathbb{E}[Y \mathbf{1}_{\{X \in A\}}].$$

Portanto, para todo  $A \in \mathcal{B}(\mathbb{R})$ ,

$$\mathbb{E}[g(X) \mathbf{1}_{\{X \in A\}}] = \mathbb{E}[Y \mathbf{1}_{\{X \in A\}}],$$

e como  $g(X)$  é  $\sigma(X)$ -mensurável e integrável, concluímos que  $g(X)$  é uma versão de  $\mathbb{E}[Y | \sigma(X)]$ , isto é, de  $\mathbb{E}[Y | X]$ .

Quanto à escolha do valor 0 quando  $f_1(x) = 0$ : ela não faz diferença para a esperança condicional, pois

$$\mathbb{P}(f_1(X) = 0) = \mathbb{P}_X(\{x : f_1(x) = 0\}) = \int_{\{f_1=0\}} f_1(x) \lambda(dx) = 0.$$

Assim, qualquer outra definição de  $g$  em  $\{f_1 = 0\}$  produziria uma função que coincide com  $g(X)$  quase certamente, e versões de esperança condicional são únicas a menos de eventos de probabilidade zero.

- ⑦ Seja  $(\Omega, 2^\Omega, \mathbb{P})$  um espaço de probabilidade em que  $\Omega$  é finito. Defina a *medida de contagem*  $c$  sobre  $(\Omega, 2^\Omega)$  como, para todo  $B \subseteq \Omega$ :

$$c(B) = |B| = \sum_{\omega \in \Omega} \mathbf{1}_B(\omega).$$

Mostre que  $\mathbb{P}$  admite densidade com respeito a  $c$ , e que essa densidade é dada por  $g(\omega) = \mathbb{P}[\{\omega\}]$ ,  $\omega \in \Omega$ .

**Resolução:**

Como  $\Omega$  é finito,  $\Sigma = 2^\Omega$  e toda função  $g : \Omega \rightarrow \mathbb{R}$  é  $\Sigma$ -mensurável. Além disso, para todo  $B \subseteq \Omega$  podemos escrever a decomposição disjunta

$$B = \bigcup_{\omega \in B} \{\omega\}.$$

Pela aditividade finita de  $\mathbb{P}$  em uniões disjuntas (aqui a soma é finita), segue que

$$\mathbb{P}(B) = \sum_{\omega \in B} \mathbb{P}(\{\omega\}).$$

Defina  $g : \Omega \rightarrow [0, 1]$  por

$$g(\omega) := \mathbb{P}(\{\omega\}), \quad \omega \in \Omega.$$

A integral com respeito à medida de contagem  $c$  coincide com a soma, para qualquer  $h : \Omega \rightarrow \mathbb{R}_+$ ,

$$\int_{\Omega} h(\omega) c(d\omega) = \sum_{\omega \in \Omega} h(\omega).$$

Logo, para todo  $B \subseteq \Omega$ ,

$$\begin{aligned} \int_{\Omega} \mathbf{1}_B(\omega) g(\omega) c(d\omega) &= \sum_{\omega \in \Omega} \mathbf{1}_B(\omega) g(\omega) = \sum_{\omega \in B} g(\omega) \\ &= \sum_{\omega \in B} \mathbb{P}(\{\omega\}) = \mathbb{P}(B). \end{aligned}$$

Portanto,  $\mathbb{P}$  admite densidade com respeito a  $c$ , e uma densidade é exatamente  $g(\omega) = \mathbb{P}(\{\omega\})$ . Como verificação adicional, note que

$$\int_{\Omega} g(\omega) c(d\omega) = \sum_{\omega \in \Omega} \mathbb{P}(\{\omega\}) = \mathbb{P}(\Omega) = 1,$$

como deve ocorrer para uma densidade de uma medida de probabilidade.

- ⑧ Se  $(\Omega, \Sigma, \mathbb{P})$  um espaço de probabilidade, e  $X$  uma variável aleatória real cuja imagem está contida num intervalo  $[a, b]$  de  $\mathbb{R}$ . Suponha que a função de distribuição de  $X$ ,  $F_X$  é contínua em  $[a, b]$ , e diferenciável em  $(a, b)$ . Mostre que a função  $g : \mathbb{R} \mapsto \mathbb{R}$ , dada por:

$$g(x) = \begin{cases} F'_X(x), & \text{se } x \in (a, b) \\ 0, & \text{se } x \notin (a, b) \end{cases}$$

define uma densidade de  $\mathbb{P}_X$  com respeito à medida de Lebesgue em  $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ . *Dica:* use o teorema fundamental do cálculo e o lema do  $\pi$ -sistema.

**Resolução:**

Defina  $\mu$  em  $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$  por

$$\mu(B) := \int_{\mathbb{R}} \mathbf{1}_B(x) g(x) \lambda(dx), \quad B \in \mathcal{B}(\mathbb{R}),$$

onde

$$g(x) = \begin{cases} F'_X(x), & x \in (a, b), \\ 0, & x \notin (a, b). \end{cases}$$

Primeiro,  $g$  é  $\mathcal{B}(\mathbb{R})$ -mensurável: como  $F_X$  é contínua, para cada  $n \geq 1$  a função

$$x \mapsto n \left( F_X \left( x + \frac{1}{n} \right) - F_X(x) \right)$$

é contínua (logo Borel-mensurável), e em  $(a, b)$  vale

$$F'_X(x) = \lim_{n \rightarrow \infty} n \left( F_X \left( x + \frac{1}{n} \right) - F_X(x) \right),$$

portanto  $F'_X$  é mensurável em  $(a, b)$  como limite pontual de funções mensuráveis; estendendo por zero fora de  $(a, b)$ , segue que  $g$  é mensurável em  $\mathbb{R}$ . Além disso,  $g \geq 0$  em  $(a, b)$ , pois  $F_X$  é não-decrescente e, para  $h > 0$ ,

$$\frac{F_X(x+h) - F_X(x)}{h} \geq 0 \quad \Rightarrow \quad F'_X(x) \geq 0.$$

Como  $X(\Omega) \subseteq [a, b]$ , temos

$$F_X(t) = \mathbb{P}(X \leq t) = 0 \text{ se } t < a, \quad F_X(t) = 1 \text{ se } t \geq b.$$

Pela continuidade de  $F_X$  em  $[a, b]$ , em particular em  $a$  e  $b$ , obtemos

$$F_X(a) = 0, \quad F_X(b) = 1.$$

Pelo teorema fundamental do cálculo,

$$\int_a^b F'_X(x) \lambda(dx) = F_X(b) - F_X(a) = 1,$$

e como  $g = F'_X$  em  $(a, b)$  e  $g = 0$  fora, segue que

$$\int_{\mathbb{R}} g(x) \lambda(dx) = 1,$$

logo  $\mu$  é uma medida de probabilidade.

Agora considere o  $\pi$ -sistema

$$\mathcal{P} := \{(-\infty, t] : t \in \mathbb{R}\}.$$

Temos  $\mathcal{P}$  é um  $\pi$ -sistema pois

$$(-\infty, t_1] \cap (-\infty, t_2] = (-\infty, \min\{t_1, t_2\}],$$

e  $\sigma(\mathcal{P}) = \mathcal{B}(\mathbb{R})$ .

Mostremos que  $\mu$  e  $\mathbb{P}_X$  coincidem em  $\mathcal{P}$ . Fixe  $t \in \mathbb{R}$ . Então

$$\mu((-\infty, t]) = \int_{(-\infty, t]} g(x) \lambda(dx).$$

Analisando casos:

- Se  $t \leq a$ , então  $g = 0$  em  $(-\infty, t]$ , logo  $\mu((-\infty, t]) = 0 = F_X(t) = \mathbb{P}_X((-\infty, t])$ .
- Se  $a < t < b$ , então

$$\mu((-\infty, t]) = \int_a^t F'_X(x) \lambda(dx) = F_X(t) - F_X(a) = F_X(t),$$

isto é,  $\mu((-\infty, t]) = \mathbb{P}_X((-\infty, t])$ .

- Se  $t \geq b$ , então

$$\mu((-\infty, t]) = \int_a^b F'_X(x) \lambda(dx) = 1 = F_X(t),$$

isto é,  $\mu((-\infty, t]) = \mathbb{P}_X((-\infty, t])$ .

Logo,  $\mu$  e  $\mathbb{P}_X$  coincidem em  $\mathcal{P}$ , então pelo **lema do  $\pi$ -sistema**, conclui-se que  $\mu = \mathbb{P}_X$  em  $\mathcal{B}(\mathbb{R})$ , isto é, para todo  $B \in \mathcal{B}(\mathbb{R})$ ,

$$\mathbb{P}_X(B) = \mu(B) = \int_{\mathbb{R}} \mathbf{1}_B(x) g(x) \lambda(dx).$$

Portanto,  $\mathbb{P}_X$  admite densidade com respeito à medida de Lebesgue, e essa densidade é  $g$ .